

TogoCoord (仮)

生命科学における様々なレイヤーの配列座標の変換を目的とした取り組み

守屋勇樹¹、藤澤貴智²、山本泰智¹

1) 情報・システム研究機構 データサイエンス共同利用基盤施設 ライフサイエンス統合データベースセンター (DBCLS)

2) 国立遺伝学研究所 生命情報・DDBJ センター

moriya@dbcls.rois.ac.jp




生命科学分野では、ゲノム、転写産物、タンパク質といった異なるレイヤーで配列情報を扱うため、複数の座標系が存在する。代表的なものとして、ゲノム座標、pre-mRNA座標、CDS座標、アミノ酸座標などが挙げられる。研究現場では、これらの座標系間の相互変換が頻繁に求められ、例えばゲノム上のバリエーションをUniProtのタンパク質配列やPDBの立体構造にマッピングする際や、生物種をまたいだオーソログ間のバリエーション比較におい

て不可欠である。特に、範囲を範囲へ変換する際には、エキソン・イントロン構造による座標の不連続性や、遺伝子の逆位なども考慮しなければならず、処理は複雑になる。加えて、アイソフォーム間の差異や挿入・欠失を伴う変異の扱いも問題を複雑化させる要因であり、これまでは個別対応に依存していた。こうした課題に対処するため、汎用的かつ再利用可能な座標変換サービス、TogoCoord (仮) の取り組みを開始した。

いろいろな座標系

生命科学における様々なレイヤーの配列は、セントラルドグマ的に、または進化的に連続しており、関連性を辿ることで互に対応を取ることが可能である。




しかしながら、実際には不連続性や逆位、付加配列（不連続な対応表で、単位と+/ーが逆転したりする）などによって複雑性が増しており、座標変換には困難が伴う。

また、同一レイヤーの座標においても、異なるデータベース間での配列の同一性の問題があるため、単純には座標を共有することはできない。ヒトにおいてさえ MANE select のタンパク質配列と UniProtKB/Swiss-Prot の代表配列が一致しない場合 (約 560 配列が TrEMBL と一致) も存在する。

実装とUI

座標間の対応を取るのためのデータや API を収集し、任意のレイヤーの任意のポジション（アノテーションの座標）を連続的に変換できるシステム構築を目的とした、ヒトやマウスなどを対象としたプロトタイプを作成。その際、INSDC Feature Table の location 記法を元にした、任意のポジションの組み合わせを ID として表現できる location ID を利用することとした。




検証実装プロトタイプでタンパク質の範囲をゲノムに変換した例

座標変換はアノテーションの伝播

異なるレイヤーの座標へと落とし込むことで、それぞれのレイヤーのアノテーションを他のレイヤーのアノテーションと比較することが可能となる。また、データの乏しい生物においても、他の生物との座標変換を経ることにより、より多くのアノテーション情報の利用が期待できる。

ヒトとマウスのゲノム座標

座標変換と共有オーソログ転写因子から、ヒトとマウスの対応する CREs 上の Variant を比較することで、実験マウスの探索を促進。(fanta.bio, ChIP-Atlas, MoG+, TogoVar 連携)



UCSC の配布している chain file を利用した liftover による座標変換

これらの座標変換は統一的な仕組みが提供されているわけではなく、個々の実装において苦労することも多い。TogoCoord のような座標に関わる包括的なサービスがあれば車輪の再開発を防ぐことが期待できる。

Location ID と FALDO JSON-LD

<https://github.com/ddbj/universal-public-genome>

GCA000000000-J000000:467

```
{
  "@context": "http://example.org/context/faldo.jsonld",
  "id": "http://example.org/GCA000000000-J000000-location",
  "faldo:location": {
    "type": "faldo:ExactPosition",
    "faldo:position": 467,
    "faldo:reference": "insdc:J000000"
  }
}
```

GCA000000000-J000000:complement(join(2691..4571,4918..5163))

```
{
  "@context": "http://example.org/context/faldo.jsonld",
  "id": "http://example.org/GCA000000000-J000000-location",
  "faldo:location": {
    "type": "faldo:ListOfRegions",
    "faldo:strand": "faldo:NegativeStrand",
    "faldo:member": [
      {
        "type": "faldo:Region",
        "faldo:begin": {
          "type": "faldo:ExactPosition",
          "faldo:position": 2691,
          "faldo:reference": "insdc:J000000"
        },
        "faldo:end": {
          "type": "faldo:ExactPosition",
          "faldo:position": 4571,
          "faldo:reference": "insdc:J000000"
        },
        "faldo:order": 1
      },
      {
        "type": "faldo:Region",
        "faldo:begin": {
          "type": "faldo:ExactPosition",
          "faldo:position": 4918,
          "faldo:reference": "insdc:J000000"
        },
        "faldo:end": {
          "type": "faldo:ExactPosition",
          "faldo:position": 5163,
          "faldo:reference": "insdc:J000000"
        },
        "faldo:order": 2
      }
    ]
  }
}
```

配列 ID とポジション
からなる新しい URI
すべての配列由来アノテーション
は Location ID で
記述可能

展望

開発版ではヒト等の一部のレイヤーのみを対象とし、検証実装を行ったが、対象とする生物種によっては座標対応のためのデータ取得や Ensembl API などの公開サービスの利用が困難である。そのため、ゲノム座標を中心とした最低限の座標変換の標準化と、アノテーションの豊富な assembly や近縁生物への LiftOver を目的とした実装についても開発を進めたい。



Database Center for Life Science

Database Center for Life Science,
Joint Support-Center for Data Science Research, Research Organization of Information and Systems
Univ. of Tokyo Kashiwanoha-campus Station Satellite 6F, 178-4-4, Wakashiba, Kashiwa, Chiba 277-0871, JAPAN

Licensed under CC-BY 4.0 ©2023 Yuki Moriya (DBCLS)

